

RELATÓRIO FINAL — PROJETO LUDEX

Aluno: Matheus Lima Ribeiro

Orientador: Prof. Alexandre Magalhães Martins

2026

Contents

1	Identificação do Projeto	3
2	Desempenho do Projeto	3
3	Desempenho em relação às entregas previstas	4
4	Principais problemas enfrentados	4
5	Questões em Aberto	5
6	Informações Adicionais (Dimensões de Wang & Strong)	5

1 Identificação do Projeto

O **Ludex** (código interno: `neolime-dev/Ludex`) é um sistema de recomendação multiestratégia para jogos eletrônicos, desenvolvido como projeto aplicado da disciplina de **Análise e Qualidade de Dados**. O sistema utiliza técnicas avançadas de NLP — especificamente **TF-IDF com N-Grams** (bigramas) e modelo **Híbrido ponderado** — para recomendar títulos com base em mecânicas de jogabilidade, gêneros e sentimento da comunidade, superando a limitação de recomendações superficiais baseadas apenas em títulos ou estética.

Características técnicas resumidas:

Atributo	Valor
Linguagem Principal	Python 3.11
Framework de Interface	Streamlit ≥ 1.35
Motor NLP	TF-IDF (scikit-learn ≥ 1.3) com N-Grams (1, 2)
Infraestrutura	Docker (containerização completa)
Volume do Dataset Final	38.918 registros $\times$ 15 atributos
Fontes de Dados	RAWG (tags) + IGDB (descrições) + Steam (imagens e IDs)
Arquivo de Dados	<code>data/processed/games.csv</code> ($\sim 46,4$ MB)
Repositório	https://github.com/neolime-dev/Ludex

2 Desempenho do Projeto

O projeto Ludex aplicou integralmente a metodologia **TQM (Total Quality Management)**, conforme o ciclo de melhoria contínua de Deming, nas seguintes fases:

1. **Importação e Conhecimento Inicial:** Ingestão de +120.000 registros brutos a partir do dataset RAWG (via Hugging Face), seguida de visualização preliminar da estrutura e esquema de dados.
2. **Data Profiling (Perfilamento):** Análise automatizada de campos nulos, duplicidades, inconsistências de formato (HTML em descrições, datas inválidas) e outliers em ratings, realizada via pipeline Python e Jupyter Notebook.
3. **Medição de Indicadores (Métricas de Qualidade):** Aplicação das métricas fundamentais:

Indicador	Fórmula	Pré-Saneamento	Pós-Saneamento
Completeness	(Campos Preenchidos / Totais)	$\sim 72\%$	89,65%
Unicidade (title)	(Únicos / Totais)	$\sim 85\%$	100,00%
Unicidade (game_id)	(IDs Únicos / Totais)	$\sim 92\%$	100,00%
Validade (positive_ratio)	(Válidos 0-100 / Totais)	—	100,00%
Validade (release_year)	(Válidos 1970-2027 / Totais)	—	99,30%

4. **Diagnóstico de Impactos:** Identificação de que 16,82% dos gêneros e 55,35% dos publishers estavam nulos nas fontes originais.

5. **Limpeza e Saneamento (Data Cleansing):** Execução de pipelines automatizados de correção:
 - Remoção de HTML das descrições
 - Eliminação de duplicatas por `title` e `game_id`
 - Filtro de conteúdo NSFW (9 keywords)
 - Enriquecimento cruzado de descrições curtas via IGDB
 - Normalização de ratings RAWG e exclusão de jogos irrelevantes
6. **Reavaliação:** Recálculo completo dos indicadores no dataset final.

3 Desempenho em relação às entregas previstas

Entrega	CrITÉRIOS de aceitação verificados
Pipeline de Ingestão de Dados	✓ Ingestão automatizada de +120k registros do RAWG via Hugging Face. Limpeza de HTML, normalização de ratings.
Fusão de Datasets (Super Dataset)	✓ Merge LEFT JOIN entre RAWG e IGDB por título. Enriquecimento condicional de descrições.
Integração de Imagens	✓ Mapeamento da Steam. Filtro NSFW. Placeholder para jogos sem capa. Blindagem de IDs únicos.
Motor de Recomendação Content-Based	✓ TF-IDF com 30.000 features, N-Grams (1,2), pesos calibrados (Tags 10x, Gêneros 5x). Perfil multi-jogo (centroide vetorial).
Motor Híbrido	✓ Ponderação adaptativa: Content (70%), Opinion (15%), Quality (15%).
Explainable AI (XAI)	✓ Decomposição do cosseno em contribuições por termo TF-IDF.
Interface Streamlit Premium	✓ Design "Steam-Style" com CSS customizado, modo escuro.
Cache Persistente	✓ Serialização em <code>.pkl</code> . Carregamento <1s.

4 Principais problemas enfrentados

Problema	Resolução adotada e recomendações futuras
Alta nulidade em campos-chave	Implementação de enriquecimento cruzado via fusão de datasets (RAWG + IGDB).
Duplicatas inter-dataset	Aplicação de exclusão em múltiplas camadas (<code>title</code> , <code>game_id</code>). Unicidade final: 100%.
Conteúdo NSFW	Filtro de segurança com 9 keywords aplicado preventivamente.
Frieza Semântica do TF-IDF	Dicionário de Query Expansion (PT→EN) com 40+ mapeamentos.
Latência de inicialização	Sistema de cache persistente (Pickle).

5 Questões em Aberto

1. **Completeness do campo publisher:** 55,35% de nulidade. Recomenda-se integração com a API da Steam.
2. **Evolução para Embeddings Densos:** Fase 2 prevê uso do Amazon Titan Embeddings (Bedrock).
3. **Validação com usuários:** Aplicação de métricas de satisfação (NDCG@10) em beta.
4. **Governança contínua:** Pipeline automatizado de re-ingestão e validação.

6 Informações Adicionais (Dimensões de Wang & Strong)

- **Intrínseca:** Precisão e Credibilidade (Ratings normalizados 0-100, filtragem de outliers).
- **Contextual:** Relevância e Completeness (Filtro top 40k, Completeness de 89,65%).
- **Representacional:** Interpretabilidade (Normalização HTML→texto, ratings 0-100).
- **Acessibilidade:** Segurança e Acesso (Filtro NSFW, Docker, Streamlit).